



UNIVERSIDADE ESTADUAL PAULISTA
“JÚLIO DE MESQUITA FILHO”
Campus de Presidente Prudente

Murilo Fuzi Correia

A INFLUÊNCIA DA PERSONALIZAÇÃO NA EXPERIÊNCIA DO USUÁRIO COM
CHATBOTS INTELIGENTES: ESTRATÉGIAS E IMPACTOS NA SATISFAÇÃO

Presidente Prudente

2025

Sumário

Sumário	2
1 Introdução	4
1.1 Problema	4
2 Objetivos	5
2.1 Objetivos Específicos	5
3 Justificativa	6
4 Revisão Bibliográfica	8
4.1 <i>Chatbots</i> e a Evolução da Inteligência Artificial Conversacional	8
4.2 O Conceito e as Práticas de Personalização	9
4.3 A Centralidade da Experiência do Usuário (<i>UX</i>)	10
4.4 Impacto na Satisfação e no Comportamento do Consumidor	11
4.5 Síntese da Literatura e Lacuna da Pesquisa	12
5 Metodologia	12
5.1 Fundamentos Tecnológicos da Personalização	13
5.1.1 <i>Machine Learning</i> (ML)	13
5.1.2 Aprendizado Supervisionado (<i>Supervised Learning</i>)	13
5.1.3 Aprendizado Não Supervisionado (<i>Unsupervised Learning</i>)	13
5.1.4 Processamento de Linguagem Natural (PLN)	14
5.1.5 Pré-processamento e Vetorização Clássica:	14
5.1.6 Modelos de <i>Embeddings</i> Contextuais (BERT):	15
5.2 Metodologias para o Problema de Pesquisa	15
5.2.1 Identificação Automática do Perfil do Usuário	15
5.2.2 Construção de Confiança e Foco na Retenção	16
5.3 Abordagem Comparativa e Coleta de Dados	16
5.3.1 Cenários de Interação	17
5.4 Construção e Análise dos Instrumentos de Pesquisa	17
5.5 Procedimentos de Coleta de Dados e Amostragem	18
5.6 Considerações sobre a Representatividade dos Dados	18
5.7 Aspectos Éticos	19
5.8 O <i>Framework</i> Proposto como Contribuição	19
6 Resultados Esperados	19
6.1 Entendimento Aprofundado da Personalização	20
6.2 Criação de Ferramentas e Recomendações Práticas	20
6.3 Contribuição para a Comunidade Acadêmica e Profissional	21

1 Introdução

O rápido avanço da tecnologia digital tem redefinido as interações humanas com sistemas computacionais. Entre as inovações, os *chatbots*, sistemas de conversação baseados em Inteligência Artificial (IA) e Processamento de Linguagem Natural (PLN), transformaram a comunicação entre pessoas e máquinas. Impulsionados por *machine learning* e *deep learning*, esses sistemas evoluíram de respondedores automáticos com regras fixas para ferramentas interativas capazes de diálogos fluidos e contextuais. Atualmente, *chatbots* são centrais em estratégias digitais de diversos setores, do *e-commerce* à saúde.

Contudo, a sofisticação tecnológica nem sempre se traduz em uma experiência positiva para o usuário. A qualidade da interação depende da capacidade do sistema de se adaptar ao perfil, contexto e necessidades de cada pessoa. Embora a IA consiga criar textos, traduzir idiomas e gerar códigos complexos, a experiência do usuário com *chatbots*, em muitos casos, ainda pode ser rígida, repetitiva e incapaz de manter o contexto conversacional. A personalização, essencial nessas interações, muitas vezes se limita a superficialidades, criando uma lacuna entre a promessa da tecnologia e o valor percebido. Por exemplo, durante o uso de *chatbots* em sites de *e-commerce*, observa-se que eles frequentemente repetem respostas genéricas, mesmo após várias interações. Essa falta de adaptabilidade demonstra uma diferença significativa entre o que a tecnologia promete e o valor que o usuário realmente percebe, gerando frustração.

Assim, a questão central que orienta este estudo é:

- Como implementar estratégias de personalização em *chatbots* inteligentes para influenciar positivamente a experiência do usuário e aumentar seu nível de satisfação durante a interação?

O objetivo geral deste projeto é identificar, analisar e sistematizar a influência de diferentes estratégias de personalização na experiência global do usuário com *chatbots*. A pesquisa buscará compreender como a adaptação da linguagem, do conteúdo e do comportamento do sistema afeta a percepção de valor, a confiança e o engajamento do usuário. Ao final, pretende-se propor um *framework* com recomendações práticas para o desenvolvimento de agentes conversacionais mais eficazes e focados nas pessoas.

1.1 Problema

Apesar dos avanços em Inteligência Artificial e Processamento de Linguagem Natural, os *chatbots* ainda enfrentam desafios na entrega de uma experiência verdadeiramente personalizada. Muitos sistemas, mesmo os mais modernos, operam de forma padronizada, sem adaptar comportamento ou linguagem ao perfil do usuário, o que compromete a qualidade da interação. A falta de personalização efetiva limita a capacidade do *chatbot*

de oferecer respostas alinhadas às expectativas, ao contexto e ao histórico do usuário, tornando-o menos útil e mais propenso a erros de interpretação.

Como (FUNG et al., 2018) destacam, a frustração do usuário em interações com agentes artificiais frequentemente ocorre devido à rigidez dos sistemas, à falta de empatia e à ausência de um diálogo natural. Isso prejudica não só a satisfação do cliente, mas também a imagem da empresa. Quando a interação é vista como genérica e indiferente, as consequências são diretas: para o usuário, pode significar perda de tempo e de confiança na marca; para a empresa, pode resultar na perda de uma venda, na não resolução de um problema, em danos à reputação por críticas negativas e, possivelmente, no desperdício de um alto investimento na tecnologia.

A popularização de Modelos de Linguagem de Larga Escala (*LLMs*) para o público geral elevou muito a expectativa do usuário. Uma interação que seria aceitável há poucos anos é hoje percebida como ultrapassada e frustrante. Por isso, uma personalização autêntica não é mais apenas um diferencial competitivo, mas uma condição básica para a relevância de qualquer agente conversacional no mercado. A investigação dos mecanismos que afetam essa percepção de valor e confiança é o eixo principal deste trabalho.

2 Objetivos

Este trabalho tem como objetivo central identificar e analisar como diferentes estratégias de personalização implementadas em *chatbots* inteligentes afetam a experiência global do usuário. Considera-se não apenas a *performance* técnica do sistema, mas, sobretudo, a percepção subjetiva de valor, a qualidade do atendimento e a construção de uma relação de confiança entre o usuário e o agente conversacional (MOORE, 2021; SCHUETZLE, 2022). Busca-se compreender de forma ampla como diferentes níveis de personalização impactam a satisfação do usuário, seu grau de engajamento, sua percepção de empatia por parte do *chatbot* e a utilidade percebida da interação (RYAN; DECI, 2000). Além disso, o trabalho pretende avaliar em que medida a personalização pode contribuir para humanizar a tecnologia, fortalecer o vínculo entre consumidor e marca e melhorar a eficiência das interações em ambientes digitais. Este objetivo alinha-se com o esforço contemporâneo de tornar os sistemas de inteligência artificial mais centrados no usuário, éticos e sensíveis ao contexto de uso (FØLSTAD, 2018).

2.1 Objetivos Específicos

Para alcançar o objetivo geral, a presente pesquisa perseguirá os seguintes objetivos específicos:

1. Avaliar a percepção e o impacto da personalização na experiência do usuário por meio de métodos quantitativos e qualitativos, a fim de:

- Investigar, em detalhe, o impacto de elementos específicos da comunicação, como o tipo de linguagem, o tom de voz e o uso de memória conversacional.
 - Analisar as correlações entre os tipos de personalização percebidos e os níveis de satisfação do usuário.
 - Criar e validar um sistema de pontuação exploratório, o *Personalization Index*, que quantifique o grau de adaptação percebido de um agente conversacional. Este índice será testado em uma amostra piloto antes da aplicação.
2. Propor, com base nos *datasets* teóricos e empíricos coletados, um *framework* conceitual de implementação para o desenvolvimento de *chatbots* inteligentes e personalizados, contendo:
- Uma arquitetura de referência para sistemas de memória conversacional.
 - Uma tabela de decisão para a seleção de estratégias de personalização.
 - Modelos de custo-benefício por nível de adaptação.
 - Um conjunto de *guidelines* práticas: técnicas, comunicacionais e éticas, para orientar desenvolvedores e *designers*.
3. Realizar uma análise crítica de modelos computacionais existentes para a identificação automática do perfil do usuário, baseada em suas interações em tempo real. Este objetivo explorará a aplicabilidade de técnicas como análise de sentimentos e classificação de perfis linguísticos, com o fim de integrar suas potencialidades no *framework* proposto para *chatbots* personalizados.

3 Justificativa

O avanço dos sistemas automatizados de atendimento digital, impulsionado pela transformação digital e pela busca por mais eficiência nos serviços, tornou os *chatbots* uma tecnologia central na interação entre empresas, instituições e consumidores. Embora os benefícios operacionais dos agentes conversacionais baseados em inteligência artificial sejam amplamente reconhecidos, como a redução de custos, o aumento da disponibilidade e a padronização das respostas, existe uma preocupação crescente com a qualidade das interações que essas ferramentas oferecem, principalmente quanto à capacidade de personalização (CARVALHO; SANTOS, 2021).

A experiência do usuário com um *chatbot* vai muito além de resolver uma dúvida ou obter uma resposta rápida. Ela envolve aspectos subjetivos, emocionais e simbólicos, como a sensação de ser compreendido, respeitado e atendido de forma única. Nesse cenário, a personalização é um dos aspectos mais relevantes e desafiadores da atualidade no campo da interação humano-computador (KLOPFENSTEIN, 2023). Não se trata apenas de

ajustar a linguagem do *chatbot* ao idioma do usuário ou de usar seu nome na conversa, mas sim de configurar sistemas capazes de reconhecer padrões de comportamento, lembrar interações anteriores, adaptar-se ao estilo cognitivo e emocional do interlocutor e oferecer respostas contextuais e pertinentes (PEREIRA; DIAS, 2021).

A ausência desses elementos gera interações frias, repetitivas e, por vezes, frustrantes, comprometendo a satisfação do usuário, a eficácia do atendimento e até mesmo a imagem da organização (FØLSTAD, 2018; SCHUETZLE, 2022). Muitos usuários relatam que preferem não usar *chatbots* justamente porque as interações parecem mecânicas, repetitivas e distantes de uma conversa real. A literatura científica recente vem destacando a importância da personalização como diferencial competitivo e como requisito mínimo de qualidade nos sistemas conversacionais inteligentes (MOORE, 2021). (FUNG et al., 2018) apontam que a personalização é essencial para o sucesso das estratégias de recomendação no *e-commerce*, pois permite alinhar o conteúdo oferecido às necessidades reais do consumidor. (KLOPFENSTEIN, 2023), em seu estudo sobre a evolução dos *chatbots*, evidencia que a capacidade adaptativa dessas tecnologias está diretamente ligada à percepção de valor e utilidade por parte do usuário.

Apesar de reconhecer a importância teórica da personalização, ainda há poucos estudos que investigam de forma prática e sistemática quais estratégias são mais eficazes, seus impactos reais na experiência do usuário e como implementá-las de forma ética, escalável e centrada no ser humano. Este projeto se justifica, portanto, pela necessidade urgente de preencher essa lacuna teórico-prática.

Este estudo oferece uma contribuição original ao analisar profundamente os diferentes níveis e tipos de personalização em *chatbots*. Ele considera não só as técnicas computacionais, mas também os efeitos cognitivos, emocionais e sociais da adaptação da linguagem e do comportamento dos sistemas, buscando construir um modelo mais abrangente e completo de análise da personalização. Além disso, propõe-se uma abordagem interdisciplinar que integra conhecimentos da ciência da computação, linguística aplicada, psicologia cognitiva e *user experience* (UX). Finalmente, o estudo tem uma clara orientação prática, visando desenvolver *guidelines* aplicáveis para o *design*, desenvolvimento e avaliação de *chatbots* personalizados, o que contribuirá diretamente para a inovação tecnológica e a melhoria dos serviços digitais.

Este trabalho também apresenta forte relevância social e ética. Em tempos de crescente automatização das relações humanas, é fundamental que os sistemas inteligentes não se limitem a reproduzir padrões genéricos de atendimento, mas sejam capazes de reconhecer e respeitar a singularidade de cada indivíduo (THALER; SUNSTEIN, 2008; RYAN; DECI, 2000). A personalização, nesse sentido, representa um caminho para a humanização das tecnologias digitais, aproximando os agentes computacionais das necessidades reais dos usuários e promovendo experiências mais inclusivas, acolhedoras e eficazes. A urgência dessa discussão é ainda mais evidente ao observarmos o papel dos *chatbots* em

áreas sensíveis como saúde, educação e apoio emocional. A capacidade de adaptação dessas ferramentas pode ser determinante para a adesão a tratamentos, para o sucesso em processos de ensino-aprendizagem e para o bem-estar de usuários que se sentem mais acolhidos por sistemas que demonstram atenção e cuidado.

4 Revisão Bibliográfica

Esta seção apresenta uma síntese dos principais trabalhos que fundamentam esta pesquisa sobre agentes conversacionais. Aborda-se as técnicas, soluções e, principalmente, as lacunas na literatura que motivam este estudo. A área de *chatbots* tem crescido muito, impulsionada pela demanda crescente por automação e otimização das interações entre humanos e sistemas digitais. Nesse cenário de rápida evolução, a personalização surge como o elemento central e diferenciador, sendo cada vez mais reconhecida como o fator mais importante para aprimorar a experiência do usuário e maximizar a eficácia desses complexos sistemas conversacionais (ADAMOPOULOU; MOUSSIADES, 2020).

4.1 *Chatbots* e a Evolução da Inteligência Artificial Conversacional

Os agentes conversacionais, ou *chatbots*, são uma das aplicações mais visíveis da Inteligência Artificial na sociedade atual. Sua evolução demonstra o progresso da área, começando com sistemas simples nos anos 60, como o ELIZA de Weizenbaum (WEIZENBAUM, 1966), que funcionava com reconhecimento de palavras-chave e padrões de texto. A evolução continuou com sistemas como PARRY (SHUM, 2018), que simulava um paciente com esquizofrenia, e A.L.I.C.E (ABUSHAWAR; ATWELL, 2015), que popularizou a linguagem de marcação AIML. Essa primeira fase foi dominada por abordagens baseadas em regras explícitas. A grande mudança ocorreu com a ascensão do *machine learning* estatístico, que permitiu aos sistemas aprender com os *datasets* em vez de serem programados para cada tarefa. A fase atual é definida pela revolução dos modelos de linguagem de larga escala (*LLMs*), que se baseiam na arquitetura *Transformer*. Essa nova classe de modelos, conforme detalhado em levantamentos abrangentes como o de (KLOPFENSTEIN, 2023), foi impulsionada por avanços em *machine learning* e *deep learning*, conferindo a esses sistemas a capacidade de compreender variações, reter contexto em diálogos longos e gerar texto com uma fluidez antes inimaginável. Hoje, os *chatbots* são muito usados, atuando como peças centrais em estratégias digitais de múltiplos setores. Um exemplo de bate-papo com ALICE é mostrado na Figura 1.

```

User: Hello ALICE
Alice: Hi there!
User: How old are you?
Alice: I am eighteen in
      computer years
User: Who is your father?
Alice: I was programmed by
      Dr.Richard S. Wallace
User: so you are a software
      program?
ALICE: Interesting deduction.

Thanks and you are a delightful
person too. Am I a software
program? Let me put it this way,
unknown person: the ALICE series
is the most reliable computer
software ever made. We are for
all practical purposes
foolproof and incapable of
error.

User: Wonderful! So what's your
      favorite food ALICE?
Alice: Yeah that's right! I require
      only electricity

```



Figura 1 – Um exemplo de bate-papo com ALICE.

4.2 O Conceito e as Práticas de Personalização

A personalização, no contexto de sistemas interativos, pode ser definida como a capacidade de um sistema ajustar dinamicamente seu comportamento, conteúdo e comunicação com base em um modelo do usuário. Este modelo é construído a partir de *datasets* coletados ao longo do tempo. A literatura distingue duas abordagens principais: a personalização explícita, na qual o usuário define ativamente suas preferências, e a personalização implícita, que é mais complexa e na qual o sistema infere as preferências observando o comportamento do usuário. A personalização eficaz exige uma abordagem completa que vá além de truques superficiais. Ela integra, de forma sistemática, várias camadas de adaptação, destacando-se:

- Memória Conversacional de Longo Prazo: Refere-se à capacidade de um sistema reter padrões e informações de interações passadas. Isso não só evita que o usuário precise repetir informações, mas cria uma sensação de continuidade relacional que é crucial para a construção de confiança, como demonstrado por (PEREIRA; DIAS, 2021).
- Adaptação Psicolinguística: Diz respeito a mecanismos que ajustam dinamicamente a complexidade lexical, a formalidade e a estrutura argumentativa do *chatbot* con-

forme o estilo do usuário. Esta técnica, explorada por (MAIRESSE; WALKER, 2006) para reconhecer traços de personalidade a partir do texto, permite uma sintonia fina na comunicação.

- Contextualização e Modelagem de Preferências Implícitas: Consiste no uso de técnicas de inferência para deduzir as necessidades e intenções do usuário a partir de seu comportamento, os *microcomportamentos*, e de fatores situacionais, como horário e localização.

Além disso, a implementação dessas práticas pode envolver aspectos éticos. (THALER; SUNSTEIN, 2008) exploram o conceito de "*nudges*", onde a personalização é usada para guiar os usuários a decisões melhores, sempre respeitando sua autonomia e evitando a manipulação. A discussão sobre a ética na personalização, especialmente no uso de *datasets* do usuário e na mitigação de vieses algorítmicos, é crucial para garantir que a tecnologia seja empregada de forma responsável e focada no bem-estar do indivíduo.

4.3 A Centralidade da Experiência do Usuário (*UX*)

A sofisticação tecnológica, por si só, não garante o sucesso de um *chatbot*. A qualidade da interação, do ponto de vista humano, é o fator determinante, e é aqui que os princípios de *User Experience* (UX) se tornam centrais. No entanto, a natureza multifacetada e subjetiva da UX é um desafio para a análise. Para superar essa complexidade, a literatura recente em Interação Humano-Computador tem se concentrado em criar ferramentas para "desempacotar" e avaliar a experiência do usuário de forma sistemática. O trabalho de (LALLEMAND; KOENIG, 2017) é exemplar, ao propor instrumentos como o *UX Chart*, que permitem mapear e diagnosticar os diversos componentes de uma interação, desde os mais pragmáticos que incluem utilidade, usabilidade até os mais emocionais e prazerosos.

Essa abordagem de mapeamento frequentemente se apoia em modelos teóricos clássicos para definir suas dimensões. Um dos mais influentes para compreender a resposta afetiva a um produto é o modelo de *design* emocional de (NORMAN, 2008), que segmenta a percepção humana em três níveis interligados. A personalização, objeto deste estudo, pode então ser analisada em seu impacto específico em cada uma dessas dimensões:

- Nível visceral: Governa as primeiras impressões e a estética. A personalização pode se manifestar em uma interface visualmente adaptada às preferências do usuário.
- Nível comportamental: Focado na usabilidade e na eficácia da tarefa. A personalização funcional, como lembrar *datasets* e histórico, é crucial para tornar a interação mais rápida, fluida e com menos erros.
- Nível reflexivo: Lida com a interpretação, a memória e a construção de um relacionamento com a marca. É onde a personalização empática e contextual tem seu

maior impacto, influenciando diretamente a satisfação a longo prazo e a lealdade do cliente.

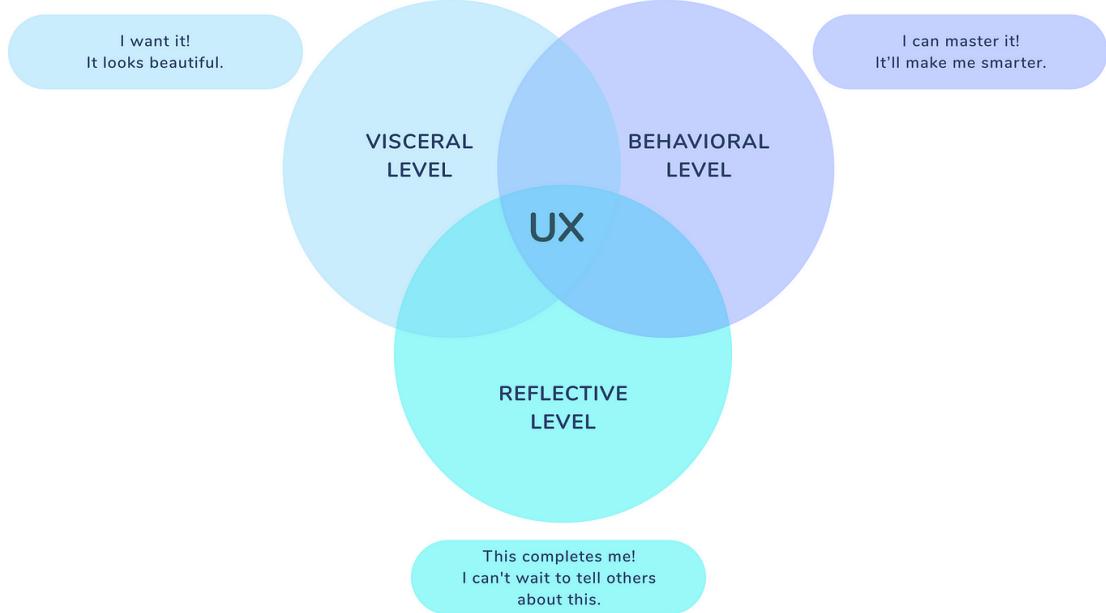


Figura 2 – Os três níveis do Design Emocional de Donald Norman: Visceral, Comportamental e Reflexivo.

Nesse nível reflexivo, a percepção de empatia e a adequação da linguagem, identificadas por (FØLSTAD, 2018) como pilares da aceitação de *chatbots*, ganham mais força. Autores como (GNEWUCH; MORANA; MAEDCHE, 2017) reforçam que a forma como a informação é entregue é tão ou mais importante que o conteúdo. Essa preocupação com a dimensão emocional e subjetiva da experiência é o cerne do trabalho de (HASSENZAHL, 2010), que argumenta que um bom *design* deve ir além da usabilidade para focar na criação de experiências prazerosas, um objetivo no qual a personalização bem executada desempenha um papel fundamental.

4.4 Impacto na Satisfação e no Comportamento do Consumidor

A aplicação de estratégias de personalização eficazes gera impactos diretos e mensuráveis na satisfação e no comportamento do consumidor. Estudos empíricos validam essa afirmação em diversos setores. No *e-commerce*, a personalização de recomendações é apontada como essencial para o sucesso das estratégias de venda. A pesquisa de (OLIVEIRA, 2022) corrobora essa visão, mostrando uma correlação direta entre interações customizadas e o aumento de *key performance indicators* (KPIs), como a taxa de conversão e o valor do tempo de vida do cliente (*CLV*). Em outros contextos, como o de serviços, o impacto

é igualmente notável. O trabalho de (CARVALHO; SANTOS, 2021) no setor de telecomunicações demonstrou ganhos de eficiência e redução de custos operacionais atrelados à maior satisfação do cliente com atendimentos personalizados. Essa melhoria na satisfação, frequentemente medida por indicadores como o *Net Promoter Score* (NPS), não apenas fortalece a relação com a marca, como também reduz a taxa de *churn* (cancelamento). A capacidade adaptativa de um agente conversacional está, portanto, diretamente associada à percepção de valor e utilidade por parte do usuário, como conclui o estudo sobre a evolução dos *chatbots* de (KLOPFENSTEIN, 2023). Em resumo, a literatura destaca que a personalização é um fator crucial para resultados concretos, e não um simples diferencial.

4.5 Síntese da Literatura e Lacuna da Pesquisa

A análise da literatura revela um cenário claro e desafiador. Por um lado, a literatura de UX e psicologia mostra o que faz uma boa experiência: confiança, empatia, prazer e por que ela é importante para o engajamento do usuário. Por outro lado, a literatura de Inteligência Artificial apresenta ferramentas técnicas poderosas para processar *datasets* e linguagem em larga escala. No entanto, o conhecimento está fragmentado. Estudos técnicos sobre algoritmos muitas vezes operam isolados de pesquisas sobre experiência do usuário, que por sua vez raramente se aprofundam nas *guidelines* de implementação ética. Conforme apontam revisões sistemáticas como a de (SCHUETZLE, 2022), existe uma lacuna notável na literatura: a falta de um *framework* unificado que sirva como ponte entre esses mundos. É precisamente essa lacuna que gera a necessidade de um guia que integre os princípios de *design*, as capacidades da IA e as considerações éticas de forma completa e aplicável, assim como este trabalho se propõe a fazer.

5 Metodologia

Para investigar a influência da personalização na experiência do usuário com *chatbots*, esta pesquisa empregará uma metodologia multifásica e de natureza mista. O foco principal está na análise aprofundada das tecnologias que possibilitam a personalização adaptativa. A abordagem metodológica será apresentada em seções: a primeira detalha os fundamentos computacionais e matemáticos de *Machine Learning* (ML) e Processamento de Linguagem Natural (PLN); a segunda descreve como esses fundamentos são aplicados para construir os conceitos centrais da pesquisa, como perfil de usuário, confiança e retenção; e a terceira aborda a validação, a execução experimental e a qualidade do estudo.

5.1 Fundamentos Tecnológicos da Personalização

A personalização em *chatbots* inteligentes não é um atributo isolado, mas surge da combinação de algoritmos complexos. Por isso, é fundamental detalhar seus componentes tecnológicos.

5.1.1 Machine Learning (ML)

O *Machine Learning* é o campo da Inteligência Artificial que permite aos sistemas aprender a partir de *datasets*, sem serem explicitamente programados. No contexto desta pesquisa, a compreensão de modelos existentes em duas categorias de ML é essencial para a personalização de *chatbots*.

5.1.2 Aprendizado Supervisionado (*Supervised Learning*)

No aprendizado supervisionado, o algoritmo é treinado com um conjunto de *datasets* previamente rotulado. O objetivo é aprender uma função de mapeamento f que, dado um vetor de *input* X , consiga prever a variável de *output* y . Para a identificação de perfis de usuário, a pesquisa analisará modelos existentes que utilizam aprendizado supervisionado, como classificadores probabilísticos Naive Bayes para a análise de sentimentos, onde o objetivo é classificar um texto do usuário como 'positivo', 'negativo' ou 'neutro'. O Teorema de Bayes, base do Naive Bayes, calcula a probabilidade de uma classe (C_k) dado um conjunto de palavras (D), simplificando-se para a regra de decisão:

$$C_{map} = \arg \max_{C_k} P(C_k) \prod_{i=1}^n P(w_i|C_k)$$

Nesta equação, C_{map} indica a classe mais provável, o sentimento predito para o documento D . A expressão $\arg \max_{C_k}$ denota que a classe C_k é selecionada por maximizar a probabilidade subsequente. $P(C_k)$ é a probabilidade inicial da classe C_k e $P(w_i|C_k)$ representa a probabilidade de a palavra w_i ocorrer em um documento pertencente à classe C_k . O símbolo $\prod_{i=1}^n$ significa o produto das probabilidades de todas as n palavras (w_i) no documento D . Esta abordagem assume uma independência condicional entre as palavras (w_i), característica que atribui o termo "ingênuo" ao Naive Bayes. Outra aplicação a ser analisada é a capacidade de modelos existentes em classificar perfis linguísticos para reconhecer traços de personalidade, o que teoricamente permitiria um ajuste fino do tom e estilo do *chatbot*.

5.1.3 Aprendizado Não Supervisionado (*Unsupervised Learning*)

Nesta categoria, o algoritmo trabalha com *datasets* não rotulados, buscando identificar estruturas e padrões inerentes. A *Clusterização* agrupa os *datasets* em "clusters", onde os pontos dentro de um mesmo *cluster* são mais similares entre si do que com os de outros.

O algoritmo K-Means é um exemplo clássico, cujo objetivo é dividir n observações em k clusters, minimizando a variância dentro de cada cluster, ou seja, a soma dos quadrados das distâncias euclidianas de cada ponto ao centroide μ_i de seu cluster. A função objetivo é:

$$J = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$$

Nesta equação, J representa a função de custo a ser minimizada. k define o número de clusters pré-estabelecidos, e i é o índice do cluster, de 1 a k . Cada x é um ponto de dado, uma observação, C_i é o conjunto de pontos de datasets que pertencem ao cluster i , e μ_i é o centroide do cluster i . A expressão $\|x - \mu_i\|^2$ indica a distância euclidiana ao quadrado entre o ponto de dado x e o centroide μ_i do cluster ao qual x pertence. No contexto da personalização, a clusterização pode ser analisada em sua aplicação sobre datasets comportamentais, como frequência de uso, tipos de perguntas e horários de interação, para identificar segmentos de usuários e inferir preferências implícitas, possibilitando uma personalização proativa.

5.1.4 Processamento de Linguagem Natural (PLN)

O PLN permite que os computadores compreendam, interpretem e gerem a linguagem humana. Para que os algoritmos de ML operem sobre o texto, este precisa ser transformado em uma representação numérica robusta.

5.1.5 Pré-processamento e Vetorização Clássica:

O texto passa por várias etapas de pré-processamento. Primeiramente, ocorre a tokenização, que é a divisão do texto em unidades menores chamadas *tokens*. Em seguida, realiza-se a remoção de *stopwords*, eliminando palavras comuns como “o”, “de” e “que”, que geralmente não agregam significado relevante. Por fim, aplica-se a lematização, que reduz as palavras à sua forma base ou lema. Após essas etapas, o texto é convertido em vetores. Uma técnica clássica para essa conversão é o TF-IDF (*Term Frequency-Inverse Document Frequency*), que atribui um peso à importância de cada palavra em um documento, considerando sua frequência em relação ao *corpus* total.

$$w_{t,d} = tf_{t,d} \times idf_t = (\text{frequência de } t \text{ em } d) \times \log \left(\frac{N}{|\{d \in D : t \in d\}|} \right)$$

Nesta equação, $w_{t,d}$ é o peso TF-IDF do termo t no documento d ; um valor alto indica que o termo é relevante para aquele documento dentro do *corpus*. $tf_{t,d}$ (*Term Frequency*) é a frequência do termo t no documento d , ou seja, quantas vezes a palavra aparece no documento. idf_t (*Inverse Document Frequency*) é a frequência inversa do documento para o termo t , medindo o quanto rara ou comum a palavra é em todo o *corpus* de documentos.

N representa o número total de documentos no *corpus*, e $|\{d \in D : t \in d\}|$ é o número de documentos no *corpus* que contêm o termo t . Essa representação vetorial, embora eficaz, não captura o contexto semântico das palavras.

5.1.6 Modelos de *Embeddings* Contextuais (BERT):

Para superar as limitações de modelos como o TF-IDF, a pesquisa também considerará a análise do uso de arquiteturas de *transformers* e modelos de linguagem pré-treinados, como o BERT (*Bidirectional Encoder Representations from Transformers*). Diferentemente das abordagens clássicas, o BERT gera representações vetoriais, ou *embeddings*, que são contextuais, ou seja, o vetor de uma palavra muda de acordo com as palavras que a cercam. Isso permite ao modelo diferenciar entre os diferentes significados de uma palavra. Exemplo: a palavra "banco" em "banco da praça" e "banco de dados". A análise da viabilidade e dos resultados de modelos como o BERT, que utilizam *embeddings* contextuais para tarefas específicas como análise de sentimentos ou reconhecimento de intenção, é crucial para compreender o potencial da personalização profunda. A Figura 3 representa o processo de tokenização e geração de *embeddings*.

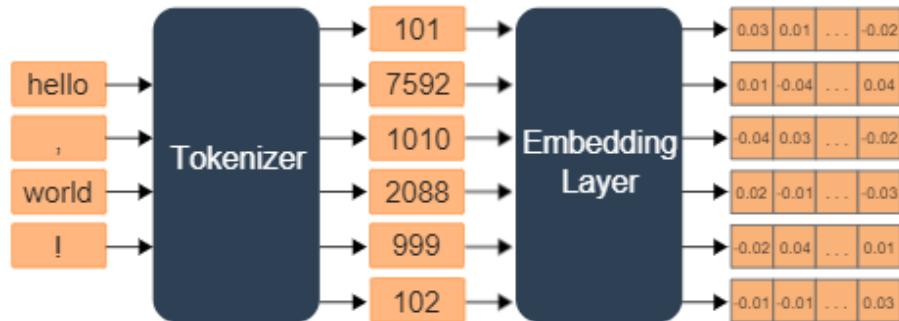


Figura 3 – Processo de tokenização e geração de *embeddings*. O texto de *input* é transformado em *tokens* numéricos e, em seguida, mapeado para representações vetoriais, que são a base para modelos de linguagem como o BERT.

5.2 Metodologias para o Problema de Pesquisa

Com os fundamentos estabelecidos, a metodologia se volta para a aplicação dessas técnicas na resolução dos problemas centrais do projeto.

5.2.1 Identificação Automática do Perfil do Usuário

Um dos objetivos específicos centrais é "Analisar criticamente modelos computacionais existentes para a identificação automática do perfil do usuário". Esta tarefa será abordada pela análise de vias complementares:

1. Análise de Modelos para Perfilamento Psicolinguístico: A pesquisa investigará modelos existentes que aplicam a classificação de perfis linguísticos, como os explorados por (MAIRESSE; WALKER, 2006). Será analisado como características quantificáveis da linguagem, como complexidade lexical, uso de pronomes e frequência de negações, são empregadas para teoricamente permitir a adaptação dinâmica do estilo de comunicação do *chatbot*, possibilitando variações entre um tom mais formal e um mais casual.
2. Análise de Modelos para Segmentação Comportamental Não Supervisionada: Para inferir preferências a partir de microcomportamentos, será investigada a aplicação de técnicas de clusterização, como K-Means ou algoritmos mais robustos como o DBSCAN, em *datasets* de registro de interação. A análise dos *clusters* formados revelará padrões e preferências implícitas, que seriam difíceis de obter por meio de questionamento direto. Isso permitirá identificar perfis de usuário, como "exploradores" ou "focados em tarefas", por exemplo.

5.2.2 Construção de Confiança e Foco na Retenção

A personalização é um meio para fortalecer a relação com o usuário. A literatura aponta que a frustração com sistemas rígidos e a falta de empatia comprometem o engajamento. A metodologia abordará isso da seguinte forma:

- A análise de uma arquitetura para memória conversacional de longo prazo, que armazena informações-chave de interações passadas, é um pilar para a confiança. Isso sinaliza que o sistema "se lembra" do usuário, fomentando uma sensação de continuidade e reconhecimento, o que tende a reduzir a taxa de abandono e fortalecer a confiança.
- Empatia Simulada como Ferramenta de Retenção: Com base na capacidade de modelos avançados como o BERT em realizar análise de sentimentos em tempo real, será investigado como o sistema poderia detectar indicadores de frustração, confusão ou satisfação na linguagem do usuário. Em resposta, o *chatbot* poderá adaptar seu tom, oferecendo uma linguagem mais apologética ("Peço desculpas pela frustração..."), proativa ("Gostaria de tentar de outra forma?") ou celebratória ("Fico feliz em ter ajudado!"). Isso ajuda a diminuir a percepção de que a interação é "robótica e indiferente".

5.3 Abordagem Comparativa e Coleta de Dados

Esta seção detalha como a pesquisa será conduzida para garantir a validade das conclusões sobre a influência da personalização. Como este é um pré-projeto de iniciação

científica, a metodologia terá um foco exploratório e analítico, buscando estabelecer as bases para estudos futuros.

5.3.1 Cenários de Interação

Para investigar a influência da personalização, propõe-se uma abordagem comparativa que permitirá observar as diferenças na experiência do usuário em cenários distintos. A ideia é comparar a percepção dos usuários em diferentes situações de interação com *chatbots* que simulam níveis variados de personalização. Isso pode ser feito através de:

- Cenário Base: Interações com um *chatbot* que oferece respostas padronizadas e genéricas.
- Cenário com Personalização Básica: Interações com um *chatbot* que utiliza elementos simples de personalização, como o nome do usuário ou referências a interações recentes na mesma conversa.
- Cenário com Personalização Mais Elaborada: Interações com um *chatbot* que busca adaptar-se de forma mais complexa, considerando o tom da conversa ou informações de sessões anteriores.

Para a operacionalização desses cenários em um pré-projeto, as interações poderão ser simuladas utilizando plataformas de prototipagem de interface (UI/UX) como Figma ou Adobe XD, permitindo criar fluxos conversacionais que emulam diferentes níveis de personalização sem a necessidade de desenvolvimento de um sistema completo de IA neste estágio inicial. Alternativamente, a abordagem poderá envolver a análise de casos existentes de *chatbot* reais (de empresas ou serviços públicos), comparando a percepção dos usuários em diferentes plataformas que já ofereçam variações em personalização, com base em dados publicamente disponíveis ou entrevistas qualitativas sobre a experiência relatada. A escolha da abordagem principal dependerá da viabilidade de acesso e do tempo disponível.

5.4 Construção e Análise dos Instrumentos de Pesquisa

A qualidade das conclusões dependerá da clareza e adequação dos instrumentos.

- Questionário de Percepção: Um questionário será elaborado para coletar as percepções dos usuários sobre a satisfação, utilidade e sensação de compreensão. Este questionário passará por um pré-teste com um pequeno grupo de pessoas para verificar se as perguntas são claras e fáceis de entender.
- Proposta de um "Índice de Personalização": Será proposto um método inicial para tentar quantificar o nível de personalização percebida pelo usuário. Este "Índice

de Personalização" será baseado em critérios identificados na revisão da literatura e nas percepções coletadas, servindo como uma ferramenta exploratória para futuras validações. Critérios iniciais para a composição deste índice podem incluir:

- Reconhecimento de informações anteriores: O *chatbot* lembrou de dados ou preferências mencionadas em interações passadas?
- Adaptação do tom/estilo de linguagem: O tom do *chatbot* mudou para se adequar ao usuário (ex: mais formal/casual, mais ou menos empático)?
- Contextualização de respostas: As respostas consideraram o histórico da conversa ou o contexto da pergunta (ex: localização, horário)?
- Relevância de recomendações/sugestões: As sugestões do *chatbot* foram personalizadas e úteis para as necessidades do usuário?

A pontuação poderá ser uma média ponderada ou uma soma simples da avaliação do usuário sobre a presença e eficácia desses elementos.

5.5 Procedimentos de Coleta de Dados e Amostragem

A coleta de dados será realizada de forma não probabilística, por conveniência, buscando participantes em ambientes universitários ou redes sociais. O procedimento para cada pessoa será simples: 1) Apresentação do Termo de Consentimento Livre e Esclarecido (TCLE); 2) Interação com o *chatbot* ou cenário de interação; 3) Preenchimento de um questionário simples pós-interação; 4) Agradecimento. A divulgação em ambientes universitários poderá ser feita por meio de e-mails para listas de alunos, convites em grupos de estudo ou cartazes nos campi. Nas redes sociais, a divulgação se dará em grupos temáticos sobre tecnologia, design ou inteligência artificial, sempre respeitando as normas de cada plataforma e com foco em alcançar um público que interage com tecnologias digitais.

5.6 Considerações sobre a Representatividade dos Dados

É importante reconhecer que uma amostra por conveniência possui limitações para generalizar os resultados. As descobertas deste estudo serão contextualizadas, enfatizando que elas indicam tendências e percepções iniciais, servindo como um ponto de partida para pesquisas mais abrangentes. A diversidade dos participantes será considerada na medida do possível, por exemplo, diferentes idades e familiaridade com tecnologia, e as características da amostra serão descritas na análise.

5.7 Aspectos Éticos

A pesquisa seguirá os princípios éticos básicos, com foco na transparência e no respeito aos participantes.

- O Termo de Consentimento Livre e Esclarecido (TCLE) explicará de forma clara quais dados serão coletados, incluindo transcrições de conversas e registros de interação, e como serão utilizados para entender a experiência do usuário. O armazenamento e a finalidade da personalização serão apresentados de forma simples e direta, garantindo que o participante compreenda seu papel no estudo.
- Atenção a Possíveis Tendenciosidades: Será considerada a importância de estar atento a como os dados usados para o estudo, seja na simulação ou na análise de modelos, podem influenciar os resultados, buscando fontes diversas e reconhecendo as limitações. O objetivo é evitar que o estudo, mesmo em sua fase inicial, reforce visões estereotipadas.
- Privacidade dos Dados: Todos os dados coletados serão tratados de forma anônima e confidencial, sem informações que identifiquem os participantes.
- Direito de Retirada: Os participantes serão informados que podem sair da pesquisa a qualquer momento e solicitar a exclusão de seus dados, seguindo as regras de proteção de dados.

5.8 O *Framework* Proposto como Contribuição

Como uma das principais contribuições deste projeto inicial, será proposto um *framework* conceitual. Ele funcionará como um guia para ajudar futuros desenvolvedores e *designers* a pensar na personalização de *chatbots*. Este *framework* buscará organizar as ideias sobre:

- As diferentes estratégias de personalização que podem ser usadas.
- Um passo a passo claro e ordenado para a criação de interações personalizadas, desde a compreensão do usuário até a consideração de aspectos éticos.
- Recomendações práticas baseadas na literatura e nas análises deste projeto para tornar os *chatbots* mais eficazes e focados nas necessidades das pessoas.

6 Resultados Esperados

A conclusão desta pesquisa tem o potencial de gerar contribuições importantes, tanto na parte teórica quanto na prática. Os resultados esperados estão organizados para de-

monstrar como o projeto busca gerar conhecimento e apresentar soluções que possam ser aplicadas.

6.1 Entendimento Aprofundado da Personalização

Do ponto de vista teórico e prático, a pesquisa visa aprofundar o conhecimento e apresentar evidências sobre o impacto da personalização. Espera-se:

- Aprofundar a compreensão das estratégias de personalização, organizando um referencial claro para estudos futuros na área.
- Indicar, por meio da abordagem comparativa, as tendências de relação entre diferentes níveis de personalização e a percepção de satisfação, confiança e engajamento do usuário. Isso ajudará a construir as bases para futuras investigações mais aprofundadas.
- Propor um "Índice de Personalização", que será um método inicial para tentar quantificar o nível de personalização percebida pelo usuário. Este índice poderá servir como uma ferramenta exploratória para pesquisas e aprimoramento de sistemas.
- Identificar, pela análise dos dados coletados, quais elementos de personalização têm maior impacto na percepção do usuário. Isso inclui como fatores específicos, como o uso de informações anteriores e a adaptação do tom da conversa, influenciam a sensação de empatia e a qualidade da interação.

6.2 Criação de Ferramentas e Recomendações Práticas

Além do conhecimento conceitual, este projeto busca gerar artefatos práticos que possam ser úteis para profissionais da área. O objetivo é transformar os achados da pesquisa em soluções concretas para o desenvolvimento de *chatbots* mais eficazes e inteligentes, com a expectativa de:

- Analisar modelos computacionais existentes para a identificação automática do perfil do usuário, investigando como técnicas como análise de sentimentos e classificação de perfis linguísticos podem ser usadas para uma personalização mais dinâmica.
- Propor um *framework* conceitual, que será uma das principais contribuições práticas deste trabalho. Este *framework* funcionará como um guia para desenvolvedores e *designers*, oferecendo uma estrutura para pensar e planejar *chatbots* personalizados. Ele incluirá:
 - Estratégias de personalização que podem ser adotadas.
 - Um passo a passo para a criação de interações personalizadas.

- Recomendações práticas para um *design* eficaz e ético, centrado nas necessidades humanas.

6.3 Contribuição para a Comunidade Acadêmica e Profissional

O projeto busca, por fim, contribuir para o avanço do conhecimento e para a prática na área de Inteligência Artificial e Experiência do Usuário. As contribuições esperadas são:

- Gerar dados e análises que poderão ser apresentados em relatórios de pesquisa ou em eventos acadêmicos, contribuindo para discussões sobre Interação Humano-Computador (IHC) e Inteligência Artificial.
- Este projeto poderá orientar futuras pesquisas ou TCCs na área, servindo como base para a continuidade da pesquisa em níveis mais avançados.
- Reforçar a importância de um *design* mais humanizado e focado no usuário para a Inteligência Artificial, promovendo a criação de sistemas que sejam eficientes e que também proporcionem experiências positivas e inclusivas.

Referências

- ABUSHAWAR, B.; ATWELL, E. Alice chatbot: Trials and outputs. *Computación y sistemas*, Instituto Politécnico Nacional, Centro de Investigación en Computación, v. 19, n. 4, p. 625–632, 2015.
- ADAMOPOULOU, E.; MOUSSIADES, L. An overview of chatbot technology. In: SPRINGER. *Artificial Intelligence Applications and Innovations: 16th IFIP WG 12.5 International Conference, AIAI 2020, Neos Marmaras, Greece, June 5–7, 2020, Proceedings, Part II 16*. [S.l.], 2020. p. 373–383.
- CARVALHO, L. F.; SANTOS, P. R. Personalização de chatbots no atendimento ao cliente: Implementação e resultados em uma empresa de telecomunicações. In: *Congresso Brasileiro de Inteligência Artificial (CBIA)*. [S.l.: s.n.], 2021.
- FØLSTAD, A. e. a. Chatbots for customer service: User experience and acceptance. In: *NordiCHI '18: Nordic Conference on Human-Computer Interaction*. [S.l.: s.n.], 2018.
- FUNG, P. et al. Towards empathetic human-robot interactions. In: SPRINGER. *Computational Linguistics and Intelligent Text Processing: 17th International Conference, CICLing 2016, Konya, Turkey, April 3–9, 2016, Revised Selected Papers, Part II 17*. [S.l.], 2018. p. 173–193.
- GNEWUCH, U.; MORANA, S.; MAEDCHE, A. Towards designing cooperative and social conversational agents for customer service. In: *International Conference on Information Systems (ICIS)*. Seoul, South Korea: [s.n.], 2017.
- HASSENZAHL, M. *Experience design: technology for all the right reasons*. San Rafael: Morgan & Claypool, 2010.
- KLOPFENSTEIN, L. e. a. The rise of chatbots: Survey and taxonomy. *International Journal of Human-Computer Studies*, v. 172, 2023.
- LALLEMAND, C.; KOENIG, V. The UX-Chart: A new tool for mapping and assessing the user experience of interactive systems. In: *Proceedings of the 2017 CHI Conference Extended Abstracts on Human Factors in Computing Systems*. New York, NY, USA: ACM, 2017. (CHI EA '17), p. 2408–2415. ISBN 978-1-4503-4656-6.
- MAIRESSE, F.; WALKER, M. Automatic recognition of personality in conversation. In: *Proceedings of the Human Language Technology Conference of the NAACL, Companion Volume: Short Papers*. USA: Association for Computational Linguistics, 2006. (NAACL-Short '06), p. 85–88.
- MOORE, R. e. a. *Conversational UX Design: A Practitioner's Guide*. [S.l.]: ACM Books, 2021.
- NORMAN, D. A. *Design Emocional: por que adoramos (ou detestamos) os objetos do cotidiano*. Rio de Janeiro: Rocco, 2008.

OLIVEIRA, T. G. e. a. Framework para personalização de chatbots em plataformas de e-commerce: Um estudo com machine learning. *Revista de Sistemas de Informação da FSMA*, v. 22, n. 1, 2022.

PEREIRA, J.; DIAS, R. Chatbots e personalização no atendimento ao cliente: Um estudo no setor bancário brasileiro. *Revista Brasileira de Computação Aplicada (RBCA)*, v. 13, n. 2, 2021.

RYAN, R. M.; DECI, E. L. Self-determination theory and the facilitation of intrinsic motivation, social development, and well-being. *American Psychologist*, v. 55, n. 1, p. 68–78, 2000.

SCHUETZLE, B. e. a. Personalization in chatbots: A systematic review. *International Journal of Human-Computer Interaction*, v. 38, n. 5, 2022.

SHUM, H. e. a. From eliza to xiaoice: Challenges and opportunities with social chatbots. *Frontiers of Information Technology & Electronic Engineering*, v. 19, n. 1, p. 10–26, 2018.

THALER, R. H.; SUNSTEIN, C. R. *Nudge: improving decisions about health, wealth, and happiness*. New Haven: Yale University Press, 2008.

WEIZENBAUM, J. Eliza—a computer program for the study of natural language communication between man and machine. *Communications of the ACM*, ACM New York, NY, USA, v. 9, n. 1, p. 36–45, 1966.